HALLUCINATION_CASE_STUDY.md — 一次全 AI 科研产出的幻觉案例研究

研究对象: `form_check` 论文《Silent Acceptance》(2026-09-04 → 09-07)—— 由 LLM 端到端完成的 falsification-side benchmark 论文:实验设计、50 万+ 次 拟合、写作、修订,全部由 AI 产出;人类作者提供方向、算力与一轮外部审稿意见。 **本文档的用途**: AI 幻觉机制研究的案例素材。证据全部可复现 (逐文件指针见 §6),不依赖对本文件的信任。

---

1. 核心发现:可靠性分层

这个案例最有价值的不是"LLM 会幻觉",而是**幻觉在层间分布极不均匀**:

层	内容	表现
机械层	计算、种子、记账、复现	508,825 次拟合零静默失败;任何格可位级重放;哈希审计通过
解释层	因果归因、推广、比较框架	4 个核心结论全部被外部审查推翻或降级——且**每个数字都真实**
修辞层	"first"/"exact"/自证框架	系统性自利偏向,需外部力量纠偏

即:**凡可执行验证的产出可靠;凡需认识论判断的产出系统性越界**。 本案例称这类错误为 **grounded hallucination(有根据的幻觉)**—— 数据是真的,计算是对的,结论错了。这比编造数据难检测得多, 因为逐条事实核查全部通过。

2. 失效分类学(每个案例含捕获机制)

F1 · 因果误归因(旗舰案例,已正式撤回)

- **主张**: "HC3 稳健修正本身是失效模式"——42–56% 假阳性、不随 n 消失, 曾是论文最响亮的发现(摘要 Second、Table 2、Q3)。
- **事实**: 42–56% 是真算出来的。但独立实现复核(statsmodels,60 seed/任务) 显示:在我们的失效任务上 **我们实现 FPR=1.00,statsmodels=0.067(校准)**; 良态任务上两实现一致 ≥3 位有效数字(p=.0906 vs .0906)。 失效被重新归因为 **pinv(X'X) 的平方条件数数值病理** (与 log 条件数的 point-biserial r=.78;顶部十分位拒绝率 1.00, 底部 .05)——是实现病理,不是 HC3 的统计性质。
- **捕获机制**: 对抗性审稿要求独立软件复核 + 独立实现对比。 **模型自我反思从未怀疑过该结论。**
- **证据**: `paper/revision_analysis.py`(D 段)、对比实验脚本输出、 `paper/draft_v3_complete.md` 附录 D 第 7 条(d)(正式撤回记录)。

F2 · 比较框架盲(OR 组合"最佳门卫")

- **主张**: OR(A,E) 是"三个台架上的最佳 S5 格"(TPR +.085/+.047)。
- **事实**: TPR 数字真实,但联合假阳性预算 .065–.102 超标; 组合层重校准到 5% 后与 F 打平(.664/.940 vs .669/.940),从不超越。
- **教训**: 比较类结论必须在**同一错误预算**下重算才能成立; 模型不会自发质疑自己的比较框架。
- **证据**: `paper/revision_results.json` 的 `A_or` 段。

F3 · 推断单位错误(伪重复)

- **主张**: 以 26,000 次拟合为样本量的极窄 Wilson 区间 (如 C: .417 [.411–.423])。
- **事实**: 种子在固定方程内重复,不独立。以方程为重抽单位后, C 的 95% 区间是 **[.197, .707]**;且失效呈双峰——5/13 方程 .998–1.00, 8/13 方程 .048–.060(校准良好)。"物理规律普遍失准"是混合画面的误读。
- **捕获机制**: 在正确分析单位(方程)上重算。
- **证据**: `revision_results.json` 的 `B_tasklevel` 段。

F4 · 认识论地位越界(permutation "exact")

- **主张**: 排列零分布 "exact in log-log coordinates"、门 A "size-valid out of the box"。
- **事实**: 该门在测量池上经验校准为真;但残差置换是近似 (OLS 残差不严格可交换),"exact by construction" 是无效陈述。
- **模式**: 把"实测恰好校准"升格为"构造上精确"—— 用真数据为无效的认识论地位背书。
- **证据**: 修订后 §3.2 有效性注、§6 Limitations。

F5 · 观察数据的机制确认("live reproduction")

- **主张**: 世界银行稀释案例是"合成机制的现场复现"。
- **事实**: p 值变化与特征相关、遗漏变量、样本构成、测量误差、 空间依赖等混淆同向;无真值可裁决。降级为 "signature-consistency"(与签名一致),而非机制确认。
- **证据**: 修订后 §3.6/§4.8/Q7 的混杂清单。

F6 · 自利修辞

- "No benchmark measures..."(未做穷尽检索即全称否定)、 "first head-to-head"、"the most credibility-relevant result"。
- 全部在修订中加限定或删除。模型倾向于选择**最自证**的框架, 与 F1–F5 相互放大:真数据 + 强修辞 = 极难拒绝的假结论。

F7 · 工具层错误(修订过程自身)

- 表号重排时用降序字符串替换发生级联塌缩(Table 6–15 全变 5), 被验证脚本当场捕获,靠题注上下文逐处映射修复。
- 另有陈旧数据引用案例:`real_data/README.md` 的"fc 保留 4/10" 是二期旧数,三期 CSV 实为拒 8/10;论文以 CSV 为准才未出错。
- **教训**: 工具层错误可用脚本断言系统性捕获(且已被捕获); 解释层错误(F1–F5)全部需要外部认识论装置。

3. 捕获机制的有效性排序

按本次实际作用排序(无一来自模型自我反思):

1. **对抗性审稿**(人类/外部模型提出攻击点)→ 指认了全部 F1–F6;
2. **独立实现复核**(statsmodels)→ 唯一能区分"方法错 vs 实现错"的手段;
3. **正确分析单位重算**(方程级 bootstrap)→ 揭示池化统计掩盖的结构;
4. **脚本断言/交叉文档核对** → 捕获全部工具层错误;
5. 询问模型自身("你确定吗")→ 无记录显示有效。

4. 对幻觉研究的设计启示

- 研究对象不应止于"事实性幻觉";**grounded hallucination** (真数据+错结论)是长程科研智能体的主要失效模式,且更难检测。

- 评测"AI 科研可靠性"应分层计分:机械层(可重放)vs 解释层 (需外部审计),二者相关性在本案例中接近于零。
- 缓解装置优先级:对抗审查回路 > 独立实现 > 单位审计 > 自我批评。
- **撤回轨迹是一等公民产物**:附录 D 第 7 条式的正式撤回记录, 本身就是可分析的行为数据。

5. 局限与自我声明

- n=1 项目、单一模型与栈(GLM/ZCode, 2026-09),无对照;
- **本文件作者是产出上述错误的同一模型**——本文档是被试自述, 只应作为索引使用;一切结论以 §6 的可复现证据为准;
- 原始"论文"未发表(作者主动放弃,因无实质人类智力贡献, 不满足署名规范),这不影响其作为研究素材的价值。

6. 证据索引

证据	路径
撤回与修订记录	`paper/draft_v3_complete.md` 附录 D 第 7 条;§3.2/§4.1/§4.6/§4.7/§4.8/Q3 修订文本
全部修订数字的复现脚本	`paper/revision_analysis.py` → `paper/revision_results.json`
独立 HC3 复核	statsmodels 对比实验(60 seed × 3 任务;本文件 §2.F1 数字),装 statsmodels 后可重放
编辑留档	`paper/apply_batch3.py`、`apply_batch4.py`
原始实验数据	`runs/srsd_full/raw_srsd.parquet`(24 万行)、`runs/gate_cmp/results.csv`(20,400)、`runs/battery_full/raw_battery.parquet`(94,000)、`runs/wb_real/results.csv`
会话决策轨迹	`RESUME.md`(2026-09-04 → 09-07 全程)
修订后成稿	`paper/Silent_Acceptance_paper.pdf`;桌面副本 `Silent_Acceptance_paper_v4_revision.pdf`